

به نوبه مرتبیت دقیقاً پیدایی یک ویژگی کمتر حساسی شود و صرف بعد آن ویژگی منافع کمینه یاراش.

انترایش عمق به استیجاری ویژگی های سمت تره تشغیل اولی به پیچیده رشتی را سلن می اند
چون با کمیش ابعاد هم ناری از اطلاعات کلن در ریتی شود شباه انترایش تعداد کانل ها این است
اطلاعات را بیان می کند.

(ب) ابعاد نیلر ها و طول stride در لایه.

در لایه کانولوشنی طول $stride=1$ چون ابعاد بهاز بهوزار فیلتر به تغییر نکرده.

اختلاف با $padding=1$ و نیلر 3×3 .

نیلر $MaxPool$ $stride=2$ چون هر سری نصف شده ابعاد.

در لایه FC فرمت کانولوشنی ها $4 \times 4 \times 16$ به هم.

ترین سری 5 ام - محمدی شریف بیلی - 402300068

A		B	
Input	$32 \times 32 \times 3$	Input	$32 \times 32 \times 3$
conv-1	3×3 , Filters=16	conv-1	3×3 , Filters=16
maxpool	2×2	Maxpool	2×2
conv-2	3×3 , Filters=32	conv2	3×3 , Filters=32
maxpool	2×2	maxpool	2×2
flatten	—	conv3	1×1 , Filters=128
FC-1	$2048 \rightarrow 128$	GAP	—
FC-2	$128 \rightarrow 10$	conv4	1×1 , Filters=10

- Q4

(آ) تفاوت اصلی: - معاری از A از $FC + Flatten$ ها است و نیلر $Flatten$ $8 \times 8 \times 32$ را
ای Vector می جوی تبدیل می کند: $8 \times 8 \times 32 \xrightarrow{Flat} \mathbb{R}^{2048}$

- معاری از B از $conv$ و GAP استفاده کرده است، $conv$ 1×1 در
همه مقیست کانل $(h \times w)$ یک ترتیب خطی از کانل ها اینم می دهد و به GAP با اینم می دهد.

$$GAP(F)_C = \frac{1}{H \cdot w} \sum_{h=1}^H \sum_{w=1}^w F_{h,w,C}$$

به یک بزرگ $1 \times 1 \times C$ می دهد و نیلر $Flatten$ نیلر.

(ب) $n_{in} \times n_{out} + n_{out}$ یا FC : $(k^2 \times C_{in} + 1) \times C_{out}$ یا $conv$ یا $conv$ یا $conv$.

$$\begin{aligned} \text{Conv 1} & (9 \times 3 + 1) \times 16 = 448 \\ \text{Conv 2} & (9 \times 16 + 1) \times 32 = 4,640 \\ \text{FC-1} & (8048 \times 128) + 128 = 262,272 \\ \text{FC-2} & (128 \times 10) + 10 = 1,290 \end{aligned}$$

• 268,650 < 10,602

A شیراز پارک شهری دارد و قابل املی
Fe4 است، این همان علق بود که
سلخ GAP رفیق.

268,650

Conv1	$(9 \times 3 + 1) \times 16$	$= 448$
Conv2	$(9 \times 16 + 1) \times 32$	$= 4,640$
Conv3	$(1 \times 32 + 1) \times 128$	$= 4,224$
Conv4	$(1 \times 128 + 1) \times 10$	$= 1,290$

10,602

Conv : $H_{out} \times W_{out} \times k^2 \times C_{in} \times C_{out}$
 FC : $n_{in} \times n_{out}$

16

Conv1 $32 \times 32 \times 9 \times 3 \times 16 = 442,368 = \text{Conv1}$
 Conv2 $16 \times 16 \times 9 \times 16 \times 32 = 1,179,648 = \text{Conv2}$
 FC1 $2048 \times 128 = 262,144 \quad \text{Conv3}$
 FC2 $128 \times 10 = 1280 \quad \text{Conv4}$

$\rightarrow 442,368$
 $\rightarrow 1,179,648$
 $\times 1 \times 32 \times 128 = 262,144$
 $128 \times 90 = 1280$

11 855,440

1,885,440

بسیار روی یکپارچه و این دو عمل روی تعداد عملیات جمع ضرب برابری دارند که دلیل آن این است که

FC-1 و conv-3 هر دو $\mathbb{R}^{178} \rightarrow \mathbb{R}^{2648}$ را این هم می‌فهمند و در نهایت تعداد عملیات یکسانی انجام می‌دهند اما پارامترهای مدل B کمتر می‌شود

(ج) A: F-15 سفید 2048 ویٹی بہ لایہ پوشی رادار، 64x64 ~ 8192 ویٹی
فی دفعہ، سیل باہر پرد آغوش بھیند۔

✓ B: چون GAP روی هر $H \times W$ پنجره همان قدرتی دارد و 4×4 ، اتوبلد می‌کنه،
قسمی Conv ها مستقل از H, W هستند و هیچ نیازی به آموزش مجدد ندارند.

1A) لایه Flatten کاملاً اطلاعات مکانی را از بین می برد و بعد از این لایه هیچ ارتباطی بین ویژگی های پیکسل ها وجود ندارد که برای پیش بینی Pixel by Pixel مناسب نیست.

B: تغییر سبب را تا قبل از GAP حفظ می کند و پس با حذف GAP و افغانه کردن decoder می توان segmentation پیکسل به پیکسل تولید کرد.

پس B اطلاعات مکانی را نگه می دارد (چون لایه Flatten ندارد) و همچنین می توان برای segmentation هم استفاده کرد.


2B) U-Net: برای Decoder-Encoder ساخته شده است، هدف اولیه آن Medical segmentation بود.

Encoder: $\text{conv} + \text{BN} + \text{ReLU} \rightarrow \text{Max Pool } (2 \times 2) \rightarrow \text{Feature map ذخیره می شود}$


Bottleneck: عمیق ترین سطح یا بیشترین کانال (1024) اطلاعات معنی دار دارد.

Decoder: Transposed conv یا $\text{Bilinear upsampling}$ ابعاد فضایی را بازسازی می کند. در هر سطح و نیچر سبب مشابه از Encoder از طریق skip connection نقلی شوند پس در لایه conv اعمال می کنیم. اطلاعات مکانی دقیق (بابت و ب) را نسبتاً از هر سطح Encoder به سطح مشابه Decoder منتقل می کند. connection skip.

Output: $\text{conv}(1 \times 1) \rightarrow \text{sigmoid}$ یا Softmax .



segNet: U-Net است که با اطلاعات spatial را به گونه متفاوتی ذخیره می کند. Encoder (از 16-72x72x3 FC استفاده می کند) در هر مرحله Maxpooling (نیمسای عالی) را به پیشینه ذخیره می شود. Decoder: برای Upsampling کردن از همان لایه های ذخیره شده استفاده می کند (Maxunpooling)؛ یعنی هر مرحله دقیقاً به موقعیت اصلی آنش برمی گردد و سایر موقعیت ها عنصری نباشند. و به همین علت می تواند به درستی به هم پیوسته باشد. U-Net از معماری TJ-Net استفاده می کند.



a	0	0	0
0	0	b	0
0	0	0	d
c	0	0	0

a	b
c	d

max-pooling
indices

Image Encoder: SAM: Vision Transformer (ViT) به تصویر را به یک بازآرایی شده تبدیل می کند. Spatial Embedding با ابعاد ثابت تولید می کند.

Prompt+Encoder: ابعادی از Prompt را encode می کند: نقشه، bbox، Mask، متن.

Mask Decoder: به کمک Transformer یک Image Embedding و Prompt Embedding را ترکیب کرده و چندین پیشگویی همراه با confidence score تولید می کند.

* این مدل روی بیش از 1 میلیارد مایل با data engine آموزش دیده امکان Zero-shot روی داده های جدید را می دهد.

TJ-Net مبتنی بر: 1. دست مرزها: رنگ های خفنی خاک لبه های چند Pixel (در مرزهای) MaxPool. Spatial info را به Decoder منتقل می کند. یعنی به هم می چسبند در TJ-Net از نوع Skip Connection، فیلترهای کامل از هر مرحله Encoder به Decoder منتقل می شود. 2. segnet: نقاط انبساطی با ذخیره می کند. segnet نقاط و جهات متاربع به پیشینه را ذخیره می کند، پس نمی تواند مرزهای دقیق را بازسازی کند.

نقش skip-connection: 1. انتقال اطلاعات نویسی بالا؛ بهمانه بردن های شدید و جزئیات مفید که در سطح این Encoder قبل از max pool وجود دارند را به Decoder سیمای می دهد.

8. رنج محدودیت Bottleneck: Bottleneck در بای پس کردنی سطح فقط اطلاعات معنایی کلی دارد اطلاعات مکانی را از دست رده است. اما skip connection ها این کمبود را رفع می کند.

← IoU و U-Net یکی از Seg Net خواهد داد.

ج. U-Net: در زمان آموزشی، تمام پیچیدگی نام سطح Encoder باید ذخیره شود و به همین علت صرف حافظه بهت زیادی دارد. به برای GPTJ ها که لایه هم بعضا اولیه.

SegNet: فعال اندیسی های max pool ذخیره می شوند و حافظه کمتری میسر می شود به برای GPTJ مناسب است.

SAM: TIT شروع می شود، این است و مدعی بیونی یا راندر در Fine-tuning آن حتی به چند GPTJ نیاز دارد و در GPTJ ها که بهی فقط Inference می سازد می توان است.

د. U-Net: با Transfer-learning و تان با تنها چند به تغییر برچسب فوری آموزشی خوبی داشته باشد. می توان می ساختیم Fine-tuning داشته باشیم.

SegNet: از U-Net پیش آموزشی دیده اشتباهات را چون skip-connection ندارد داده های بیشتری برای یادگیری می سازد و نیاز به داده های برچسب فوری دارد.

SAM: روی پیش از این کارها که آموزش دیده و می توان Zero-shot کرد و نیازی به برچسب ندارد و برای اثر دانه ها نیز می توان بدون آموزش استفاده کرد.

1. نایب بینی (تور مغزی با 500 تصویر برچسب فوری) U-Net و می تواند از داده های کم بهت استفاده را ببرد و ادلی با برابری بهت و پرتی می شود.

8. نامی بینی اندی شانه شده در تقویم اینترنتی بدون آموزش مجدد

به SAM: دیتا با همی هم می گوی که با zero-shot seg روی و تصویر دیتا بدون آموزش بهر دست بالایی است.

3. می توان بهت اندی می یک دستگاه Embedded با حافظه محدود که SegNet: اکثری حافظه صرف می کند، نیازی به ذخیره نام Feature map ها نیست، SAM اندی Embedded Device می قابل پیک سازی نیست.

4. جنبش پذیری دقیق برزیکسل هادر تعریف می شود و به نام U -Net $\rightarrow$ نیاز مندی spatial info دقیق داریم.

GT1, GT2, GT3, GT4 داریم.

$$P_1 = 0.99, P_2 = 0.96, P_3 = 0.91, P_4 = 0.89, P_5 = 0.84, P_6 = 0.78, P_7 = 0.56, P_8 = 0.38, P_9 = 0.25$$

ان NMS ، $Iou = 0.50$

P_1 :

P_2, P_1 دارای همپوشانی Iou واقعی 0.85 هستند. $0.85 > 0.50 \rightarrow P_1 > P_2 \rightarrow P_2$ حذف شود.

P_3, P_1 و P_3, P_2 و P_3, P_4 همپوشانی 0.65 هستند. $0.65 > 0.50 \rightarrow P_1 > P_3 \rightarrow P_3$ حذف شود.

بالا $Iou = 0.50$ باشد یعنی هر دو P_1 و P_2 بیش از حد همپوشانی دارند، پس باید با استیلا پاشی آن حذف شود.

P_4 :

P_6, P_4 $Iou = 0.55$ $0.55 > 0.50 \rightarrow P_6 < P_4 \rightarrow P_6$ حذف شود.

P_5 :

P_5, P_3 $Iou = 0.30$ $0.30 < 0.50 \rightarrow P_5$ از دیگر همپوشانی کمتر.

P_7 :

P_8, P_7 $Iou = 0.75$ $0.75 > 0.50 \rightarrow P_8 < P_7 \rightarrow P_8$ حذف شود.

باقی $P_1, P_4, P_5, P_7, P_8, P_9$ باقی می ماند. و P_2, P_3, P_6 حذف می شود.

ب) TP: کلاسی که نتایج واقعی را به درستی پیدا کرده ($Iou > 0.50$)

FP: کلاسی که یارویی پس زمینه اشتباه باشد یا بیش از حد (نتیجی را که در آن اشتباهی داده باشد).

FN: نتایج واقعی در مقبول نبوده نتوانسته تشخیص دهد.

پیش بینی های باقی مانده از ان $P_1, P_4, P_5, P_7, P_8, P_9$

$P_1 \leftarrow Iou(GT_1) = 0.90$

$P_4 \leftarrow Iou(GT_2) = 0.88$

$P_5 \leftarrow Iou(GT_3) = 0.45$ $0.45 < 0.50 \rightarrow FP$

$P_7 \leftarrow Iou(GT_4) = 0.80$ TP

$P_9 \leftarrow Iou = 0$ FP

تا GT_3 بود توسط سطح پیشی (پیشی) به عنوان مثبت نشود FN است.

برای GT_4 P_2 حذف شده و هر دو کلاسی FP حذف شده.

• برای GT_2 P_2 حذف شده باز شکلی برود $\rightarrow 1FP$ حذف شده.

• برای GT_4 P_8 " " " $\rightarrow 1FP$ حذف شده.

• تعداد FP های کوب یکبار.

$$F_1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad \text{Recall} = \frac{TP}{TP + FN} \quad \text{Precision} = \frac{TP}{TP + FP} \quad (1)$$

$$2x \frac{0.6 \times 0.75}{0.6 + 0.75} = \frac{0.9}{1.35} \times \frac{2}{3} = 0.66 \quad \left(\frac{2}{3+1} = \frac{2}{4} = 0.75 \right) \quad \left(\therefore 0.6 \times \frac{2}{5} = \frac{3}{3+2} \right)$$

recall	Precision	FPs	TPs	Score	
$\frac{1}{4} = 0.25$	1	0	1	0.99	P_1
$\frac{2}{4} = 0.5$	1	0	2	0.89	P_4
$\frac{2}{4} = 0.5$	$\frac{2}{3} = 0.66$	1	2	0.84	P_5
$\frac{3}{4} = 0.75$	$\frac{3}{4} = 0.75$	1	3	0.56	P_7
$\frac{3}{4} = 0.75$	$\frac{3}{5} = 0.6$	2	3	0.25	P_9

$$AP_2 \left[(\Delta \text{Recall}) \times \text{Precision} \right] \quad (\leftarrow)$$

$$= (\text{Recall } p_1 - 0) \times \text{Precision } p_1 + (\text{Recall } p_4 - \text{Recall } p_1) \times \text{Precision } p_4$$

$$+ (\text{Recall } p_5 - \text{Recall } p_4) \times \text{Precision } p_5$$

$$+ (\text{Recall } p_7 - \text{Recall } p_5) \times \text{Precision } p_7$$

$$+ (\text{Recall } p_9 - \text{Recall } p_7) \times \text{Precision } p_9$$

$$= 0.75 \times 1 + (0.50 - 0.75) \times 1 + 0 + (0.75 - 0.50) \times 0.75 + 0$$

$$= 0.75 + 0.25 + 0.1875 = 0.8875$$

برای ۹۵٪ تا ۱۰۰٪ است. چون نکته بزرگی Recall بیشتر از مزایای (۰.۷۳) Precision منوط است.

مث (۲) نقش دگانه IoT : دربردارنده NMS : در اینجا IoT بی درگاه پیش بینی شده می باشد می شود تا هم پوشش کافی آن ها را برآید . رعت آنکه هر دری شی را پیش بینی می کنند یا فید . رستی بی با اطمینان کمتر در مدت IoT باز رفت می شود . ع فرفه استلاری ها .

در مدل ارزبای: در اینجا IoT بین ملک کاربریشی پیی شده و آقا ها به هم مشوره و هدف انیده آيا پيشی
بینی به ارزبای کافی دیت است یا فیدر به بخوان TP دلی اکن پیی شده و بشود به ارزبای دیت


i: curve interpolation (ب)

اعدادی نه قوی است رانیم فیلی بالا و یا بیجی و ششده مثلا از $P_1: 1$ تا $P_5: 0.67$ و یا از $P_7: 0.75$ و $P_8: 0.8$.

نخفہ بمقدیل شدہ، این بالادیکسیہ کارامی کی کونہ یعنی اندر سی در سطح بالادری و موت ۷۵۰ راکب کردہ، نہایہ چلی بری استقامت کویک در سیدہ دست های بلی استی را ۶۷۰ در سفلہ کندیہم در روشی دون یابی کا بہ جایی مقدار نفی دست و بیش تر کی سدا و دمی کہ از اینجا بہ بعد دیہ شود راجع الیہم کی کونہ.

(ج) 1. ہمارے FP میں P_1, P_2, P_3, P_4 و FP کی شہدیت FP_4 اعلیٰ ترین ہے۔

هم گامتی و یاب. $AP \rightarrow$
چون در سطح های بالایی جدول سازه FP آسانه ها شونده و سختی
حقیقی زود است می کنند.



VGG16 - Structural Details														
#	Input Image			output			Layer	Stride	Kernel			in	out	Param
1	224	224	3	224	224	64	conv3-64	1	3	3	3	64		1792
2	224	224	64	224	224	64	conv3064	1	3	3	64	64		36928
3	224	224	64	112	112	64	maxpool	2	2	2	64	64	0	
4	112	112	64	112	112	128	conv3-128	1	3	3	64	128		73856
5	112	112	128	112	112	128	conv3-128	1	3	3	128	128		147584
6	112	112	128	56	56	128	maxpool	2	2	2	128	128		65664
7	56	56	128	56	56	256	conv3-256	1	3	3	128	256		295168
8	56	56	256	56	56	256	conv3-256	1	3	3	256	256		590080
9	56	56	256	56	56	256	conv3-256	1	3	3	256	256		590080
10	56	56	256	28	28	256	maxpool	2	2	2	256	256	0	
11	28	28	256	28	28	512	conv3-512	1	3	3	256	512		1180160
12	28	28	512	28	28	512	conv3-512	1	3	3	512	512		2359808
13	28	28	512	28	28	512	conv3-512	1	3	3	512	512		2359808
14	28	28	512	14	14	512	maxpool	2	2	2	512	512	0	
15	14	14	512	14	14	512	conv3-512	1	3	3	512	512		2359808
16	14	14	512	14	14	512	conv3-512	1	3	3	512	512		2359808
17	14	14	512	7	7	512	maxpool	2	2	2	512	512	0	
18	1	1	25088	1	1	4096	fc		1	1	25088	4096		102764544
19	1	1	4096	1	1	4096	fc		1	1	4096	4096		16781312
20	1	1	4096	1	1	1000	fc		1	1	4096	1000		4097000
Total														138,423,208

5x maxpool (s=2) $\rightarrow 2^5 \times 3 \times 2$

$$\rightarrow \frac{512}{32} \times \frac{512}{32} = 16 \times 16 \times \frac{512}{4}$$

ملء 14: FEL : فيزياء 7X7 - فصل 14

Strukturpadding - 7x7

$$\xrightarrow{\text{Solving}} 0 = \frac{w-k}{8} + 1 \rightarrow 0/4 = \frac{16-k}{8} + 1 = 10$$

این لایه 40% نیلر دار ← فرم $10 \times 10 \times 40\%$ خواهد بود.

$\leftarrow FC8:15_{N4} \leftarrow (1 \times 1)_{\text{conv}} \leftarrow \text{فرد } 3 \times 4096 \times 1 \times 1$

FC3 : 16 nu ← (1x1) cmv ← 1000 mly ← خزینه 1x1x1000 فواره ب.د.

$$512 \times 512 \times 3 \xrightarrow{\text{conv}(3/3)} 512 \times 512 \times 64 \quad .2$$

برای یک دانه از فریب: تعداد فریب: $27 = \frac{3 \times 3 \times 3}{k}$ فریب برای سلیب فریبها، جمع

16 Pixel = $512 \times 512 \times 64 = 16,777,216$

قسط ۱۷ - $16,777,916 \times 17 = 452,984,832$

$$698 \rightarrow 4 \times 17 = 4$$

شکل ۱: جزئیات ساختاری شبکه VGG16

3. وینچ شبکه خبری 40x10 است و یعنی که بران دیکه شبکه ماری 100 کان از تقویر اصلی حرکت کرده است.

محاسبه برای با ابعاد خبری لایه اول: $224 \times 224 \times 64 = 3,211,264$ px

ضرب ها برای یک برش: $3,211,264 \times 27 = 86,904,128$

جمع ها: $86,904,128$ $\times$ 8 $=$ $695,233,024$

محاسبه برای 100 بار ابعاد: $86,904,128 \times 100 = 8,690,412,800$ $\times$ 8 $=$ $69,523,302,400$

جمع ها: $8,690,412,800$ $\times$ 8 $=$ $69,523,302,400$

تایید: در حالت کاملاً کانولوشنی، تعداد ضرب ها جمع صدها 453 میلیون پردازش (مانند) به بیش از 8 میلیارد

ضرب افزایش یافته. 19 به $8,600$ $\times$ 453 $=$ $3,898,800$ برابر عا به بیشتر.

1. در R-CNN ابتدا حدود 2000 نمونه پیش‌بینی از تقویر نام استخراج می‌شود، پس هر یک از این 2000 نمونه تقویر تغییر اندازه داده شده (Warp) و به صورت کاملاً مثل دارد شبکه کانولوشنی می‌شوند.

این فرآیند به دلیل موجب computational Backbone شدید می‌شود.

و شبکه مثل VGG به خصوصی خود گنجان است. حال در R-CNN برای پردازش تعدادی تقویر این شبکه گنجان باید 2000 بار جداگانه ران شود.

و این 2000 نمونه پیش‌بینی در تقویر به صورت با هم هم‌چنانی دارند، یعنی شبکه روی همان تصویر به صورت مستقل اجرا می‌شود. اما لازم است که در فضای مشترک فیزیکی ناحیه قرار بگیرد، بارها توسط فیلترهای Conv گنجان پردازش می‌شوند و برای کشف ویژگی‌هایی که از قبل عا به شده و بازی است می‌کنند.

2. Fast R-CNN: با computational sharing شکل تکرارهای بی‌محدود را حل می‌کند.

R-CNN: برش‌های از مقایسه $\rightarrow$ اجرای کانولوشن روی هر برش

Fast R-CNN: اجرای کانولوشن روی کل تقویر $\rightarrow$ برش‌های از روی Feature map

در Fast R-CNN لایه‌های کانولوشنی (مثل VGG) فقط یک بار روی کل تقویر ورودی اعمال می‌شوند. خروجی این لایه‌ها روی Final Feature map است. سپس، آن 2000 نمونه پیش‌بینی که آلگوریتم selective search پیدا کرده بود به جای آنکه روی تک‌تک تصاویر اعمال می‌شوند، روی این Feature map و تقویر (Proposal) می‌شوند.

RoI Pooling (پ)

1.1: گشت (Projection): ابتدا مختصات Region Proposals (روی تقویر اصلی قرار دارد) به مختصات Feature map منتقل می‌شود. شبکه‌ها شبکه در مجموع ابعاد را کاملاً یکپارچه می‌کند (در است) و مختصات ناحیه نیز بر 16 تقویر می‌شود تا جایگاه دقیق آن روی Feature map پیدا شود.

1.2: Quantization: چون مختصات به دست آمده از برده قبل عدد صحیح نیستند، این لایه

مختصات را به نزدیکترین اعداد صحیح snap می‌کند تا ناحیه به شکل یک شبکه یکپارچه در برسد.

2.3: Grid Division: حالا این ناحیه استخراج شده که ابعاد دلخواهی $h \times w$ دارد باید به تعداد مشخصی از مدل های $sub_windows$ تقسیم شود. اگر هدف ما تولید یک خروجی $H \times W$ (مثلاً 7x7 برای YOLO) باشد، ناحیه باید به شکل $H \times W$ تقسیم می شود.

4.4: Max Pooling: در نهایت، لایه های تک تک این زیر پنجره ها مرکب شده و بزرگترین مقدار موجود در هر زیر پنجره را به عنوان نماینده آن بخشی انتخاب می کنند.

8. چگونه Pool Pooling ابعاد تغییر یافته را ثابت تبدیل می کند؟

در $max_pooling$ ، اندازه کنترل ثابت است و خروجی مقید می شود. اما در $Roll Pooling$ این منطق برعکس است: جایی مانع که خروجی $h \times w$ باشد، در نهایت چه اندازه ای باشد، بنابراین اندازه نهایی را بر اساس خروجی تعیین می کنیم.

هنگامی که ناحیه $h \times w$ در یک $h \times w$ باشد،

و ناحیه $h \times w$ ثابت با ابعاد $H \times W$ می فعالیم.

و لایه $Roll Pooling$ ابعاد ناحیه را بر ابعاد خروجی تقسیم می کند:

$$\frac{h}{H} \times \frac{w}{W}$$

همین از تقسیم شدن ناحیه بزرگتری و در درون هر کدام از این زیر پنجره ها عملیات $max_pooling$ می انجامی می شود و نهایتاً تعداد بیشینه آن پنجره انتخاب می شود.

این کار مستقیماً بر روی یک کمد کانال های ویژگی عمل می شود. با استخراج مقدار max از هر یک از کانال های max ، مهم حفظ شده و در عین حال که شکل از ابعاد اولیه خروجی همانند با ابعاد کانال ها ثابت است.

Fast R-CNN

1. الگوریتم $selective\ search$ برای یافتن 2000 ناحیه $proposal$ در یک cpu ای است.

معادله $Fast R-CNN$ و h به چه مقدار شده یا تولید نهایی را پیشنهاد دهد؟

در یک شبکه عصبی کوپلی تمام کانال های $feature$ به نام RPN (Region Proposal Network) را می توان به مدل های افزود.

2. Sliding window: شبکه RPN یک پنجره فعال کوپلی را روی $feature\ map$ (Final Feature map) می کشد (ConvNet) تولید کرده است و مرکب می دهد.

Anchors: در هر مکان از این پنجره فعال، شبکه از تعدادی کادر مرجع به نام $anchors$ استفاده می کند. معمولاً در هر مکان 5 کادر با اندازه ها نسبت های ابعاد مختلف موجود دارد تا شبکه بتواند اشیاء را از آن مشخصات را پیش دهد.

خروجی های در کادر برای هر $anchor$ و RPN در خروجی تولید می کند:

Objective Score: یک طبقه بندی باینری که می تواند برای کادر های $foreground$ است یا $background$ است (PR خروجی).

Bounding box Regression: چهار عدد که نشان می دهد ابعاد و مختصات این کادر چقدر باید جابه جا و $scale$ شود تا دقیقاً در درستی را بگیرد. (شکل 4.4 خروجی)

نمی‌چونند RPN باعث End-to-End می‌شود؟

و **Unified loss**: از آنجایی که RPN خودش یک شبکه محلی با پارامترهای وزن دار است، می‌توانیم loss آن را اضافه کنیم. حالا کل سیستم می‌تواند loss ترکیبی دارد. (اضافی RPN + خطای رگرسیونی Fast R-Cnn).

و **Back propagation**: با داشتن لایه تابع نرالی‌زاسیون می‌توانیم با back propagation از فزونی‌ها شروع کنیم و تغییرات را به RPN و Conv Net به طور معزبان آپدیت کنیم. به عبارت End-to-End آموزشی می‌بینیم.

* چون RPN خودش وابسته به شبکه‌های میزبان است، هر دو نقشه و ویژگی می‌تواند را به اشتراک می‌گذارند، هزینه استخراج توانایی تقسیم به صورت مشترک است. (Shared computational).